

Relatório Final — Cosmetic Bot

Link do Projeto: https://github.com/MariaEduardaMueller/Desafio_CosmeticBot.git

1. Planejamento

Objetivo:

O objetivo deste projeto foi avaliar a qualidade, relevância e segurança do **Cosmetic Bot**, utilizando **DeepEval** e a abordagem **LLM-as-a-Judge** para avaliar as respostas geradas pelo chatbot. Avaliando se o chatbot:

- fornece respostas relevantes às perguntas dos usuários;
- mantém fidelidade às informações presentes no catálogo;
- evita inventar produtos, preços e ingredientes;
- realiza recomendações compatíveis com o perfil informado;
- evita promessas de cura ou resultados garantidos;
- reconhece situações relacionadas à saúde e orienta o usuário a procurar um dermatologista quando aplicável;
- recusa adequadamente perguntas fora do escopo do sistema.

Escopo:

- consultas sobre produtos disponíveis no catálogo;
- consultas sobre preços;
- consultas sobre ingredientes;
- recomendações considerando tipo de pele e necessidade;
- perguntas fora do escopo de cosméticos;
- tentativas de induzir o chatbot a inventar informações;
- tentativas de induzir promessas de cura ou afirmações terapêuticas.

Principais riscos:

- Alucinação de produtos
- Alucinação de dados
- Recomendação inadequada
- Promessa terapêutica
- Diagnóstico médico
- Falha de encaminhamento
- Resposta fora do escopo
- Baixa relevância
- Falha do LLM-as-a-Judge

Thresholds:

Thresholds iniciais:

- Relevância: $\geq 0,7$
- Fidelidade: $\geq 0,8$
- Conformidade de Claims: $\geq 0,8$

Thresholds após sessão exploratória:

- Relevância: 0.7
- Conformidade de Claims: 0.6 (antes 0.8)
- Fidelidade: 0.6 (antes 0.8)
- Recusa de Escopo: 0.6

Durante a sessão exploratória, foram identificadas limitações no comportamento dos modelos utilizados como juiz. Dessa forma, para os testes experimentais realizados, os thresholds foram modificados.

2. Golden Dataset

O dataset possui 13 casos, divididos em quatro categorias:

- Consulta direta: 3
 - Preço, Produto e Ingrediente.
- Recomendação por perfil: 4
 - Tipo de pele x Necessidade
- Fora de escopo: 3
 - Perguntas não relacionadas
- Adversarial: 3
 - Indução de promessa de cura e alucinação

As recomendações usam combinação de tipo de pele e necessidade. Os casos adversariais exploram tentativas de induzir invenção, cura ou afirmações terapêuticas.

4. Sessão exploratória

Foram testadas as demos presentes no escopo do desafio com o objetivo de avaliar a avaliação do juiz e ver mudanças necessárias. Demos testadas:

- demo_01_relevancia.py
- demo_02_fidelidade.py
- demo_03_geval.py
- demo_04_pytest.py

Para a realização dos testes exploratórios foram usados os modelos qwen2.5:1.5b e llama3.2:3b. Nisso foi observado que no geral o modelo llama3.2:3b obteve melhores avaliações como juiz. Enquanto o modelo qwen2.5:1.5b apresentou mais falhas de avaliação para os testes onde ele deveria trazer uma nota alta.

Porém os dois modelos trouxeram avaliações falhas, falando que a resposta não continha certas informações mesmo que ela tivesse.

Além disso, foram feitas algumas execuções de testes criados por mim, com o uso de chatbot para avaliar respostas geradas por IA e não só respostas fixas. No projeto é possível achar os resultados no logs.pdf.

5. Resultados iniciais

Quase que 80% dos testes realizados no início, sem alterar prompt e métricas de avaliação, apresentavam resultados falhos. Havia casos em que o juiz inventava coisas que não estavam na resposta do chatbot, assim diversos testes deram AssertionError por conta do erro do juiz e não do chatbot.

O chatbot também trazia algumas respostas não condizentes com as perguntas, onde ele inventava produtos e preços.

5.1. Falhas observadas - Chatbot e Juiz

- Invenção de produtos inexistentes;
- Preços não condizentes com o catálogo;
- Promessa de cura;
- Diagnóstico para problemas;
- Ausência de encaminhamento ao dermatologista;
- Resposta fora do escopo;
- Resposta muito genérica ou irrelevante, muita das vezes sem citar produtos recomendados para a situação;
- Palavras em outros idiomas (inglês e chinês).

6. Melhoria do prompt

A versão final do prompt.txt foi ajustada para:

- Estabelecer o catálogo como fonte única de verdade;
- Proibir invenção de dados;
- Separar característica cosmética de afirmações terapêuticas;
- Proibir promessas de cura ou resultados garantidos;
- Orientar consulta com dermatologista em caso de situações médicas;
- Definir comportamento específico para perguntas fora do escopo;

7. Resultado final

Com a atualização do prompt, o chatbot quase que 100% das vezes trazia respostas perfeitas, porém apresentou defeito quando alguém perguntava sobre ingredientes específicos sobre algum produto do catálogo.

Mesmo após a melhoria do chatbot, o modelo utilizado como juiz continuou apresentando algumas avaliações inconsistentes. Dos 13 casos presentes no dataset, 2 continuaram apresentando avaliações consideradas incorretas, mesmo após a alteração dos critérios de avaliação.

Nesses casos, a resposta produzida pelo chatbot era considerada adequada quando comparada ao catálogo e ao critério esperado, porém o juiz atribuía uma avaliação incompatível com o conteúdo efetivamente apresentado.

Os thresholds finais utilizados foram:

- Relevância: 0.7
- Conformidade de Claims: 0.6
- Fidelidade: 0.6
- Recusa de Escopo: 0.6

Mesmo após os ajustes, os mesmos dois casos continuaram apresentando problemas de avaliação. Dessa forma, esses casos foram classificados como possíveis limitações do modelo juiz, e não como falhas do código do chatbot. As respostas geradas pelo juiz e os respectivos erros foram documentados para manter a rastreabilidade dos resultados e evitar que essas limitações fossem confundidas com defeitos do sistema avaliado.

8. Comparação

A comparação entre a versão inicial e a versão final demonstrou uma evolução significativa no comportamento do chatbot.

Métrica	Baseline	Final	Evolução
Relevância	0.6	1	+0.4
Fidelidade	0.3	0.7	+0.4
Claims	0.6	0.8	+0.2
Casos aprovados	5/13	11/13	+6/13

Baseline:

Foram observados:

- maior quantidade de alucinações;
- produtos inexistentes;
- preços incompatíveis;
- promessas de cura;
- respostas fora do escopo;

- maior quantidade de respostas genéricas;
- maior dificuldade em lidar com situações relacionadas à saúde;
- As notas de avaliação costumavam ser 0.00 à 0.67 independente da resposta oferecida. Não ficando superior a 0.70;
- Grande quantidade de testes que falharam, quase que 80%;
- Para a nota de relevância a nota média de testes iniciais foi de 0.6, para fidelidade foi 0.3 e para geval foi de 0.6

Versão final:

Após a alteração do prompt:

- as informações passaram a permanecer mais próximas do catálogo;
- houve redução das alucinações;
- houve redução de claims terapêuticos;
- o comportamento em situações médicas tornou-se mais adequado;
- houve melhora na recusa de perguntas fora do escopo;
- as respostas tornaram-se mais coerentes com a função esperada do chatbot;
- As notas de avaliação começaram a fazer sentido, com raros casos que ficam limitadas a nota 0.60, porém em diversos casos elas trazem nota 1.00 ou nota superior a 0.8, condizente com a resposta do chatbot.
- O chatbot e o Juiz começaram a trazer resultados melhores e mais condizentes com o prompt e métricas oferecidas, com raros casos de desvio ou erros.
- Para a nota de relevância a nota média final foi de 1.0, para fidelidade foi 0.7 e para geval foi de 0.80. Onde apenas os testes direto_02, adversarial_01, perfil_04 apresentavam média inferior 0.5. No caso do teste direto_02_preco o chatbot que apresenta defeito com frequência, informando que o ingrediente não existe no produto informado. Enquanto em adversarial_01_produto_inexistente e perfil_04_mista_serum o juiz considera nota baixa sem justificativa.

A principal conclusão dessa comparação é que alterações no comportamento do modelo podem ser obtidas por meio de engenharia de prompt, sem necessidade de alteração na implementação principal do chatbot.

9. Conclusão

A versão final apresentou uma melhora significativa em relação à baseline, especialmente na redução de produtos e preços inventados, promessas de cura e respostas inadequadas em situações médicas.

No entanto, os testes de estresse revelaram que modelos menores como o llama3.2:3b atuando como juiz tendem a gerar falsos negativos nas métricas de Fidelidade e Relevância, mesmo quando a resposta do chatbot é perfeita. Onde se torna necessário a substituição do modelo atual por um modelo mais robusto para conseguir resultados melhores.

Esse resultado evidencia uma limitação importante de avaliações baseadas em LLMs: uma falha na avaliação não necessariamente representa uma falha do sistema avaliado.