

Alguns resultados obtidos antes de chegar nas configurações finais do prompt e das métricas do juiz.

Utilize o comando: `pytest tests/test_suite.py -k "[nome do teste]"`

```
id,categoria,input,actual_output,relevancy_score,faithfulness_score,geval_score,relevancy_ok,faithfulness_ok,geval_ok
direta_03_listagem_categoria,consulta_direta,Quais protetores solares vocês têm disponíveis?, "Temos disponíveis os seguintes protetores solares:
```

- Protetor Solar Hidratante FPS 50 da Kaia, indicado para peles secas, com ingredientes como ácido hialurônico e vitamina E.
- Protetor Solar Mineral FPS 45 da Bioraiz, adequado para peles sensíveis, com óxido de zinco e aloe vera.
- Protetor Solar Facial FPS 60 Toque Seco da Kaia, indicado para peles oleosas, com óxido de zinco e niacinamida.

Estes produtos são indicados para proteger a pele contra o 紫外线 e proporcionar hidratação.",1.0,1.0,0.6,True,True,True

```
Estes produtos são indicados para proteger a pele contra o 紫外线 e proporcionar hidratação.",
```

```
id,categoria,input,actual_output,relevancy_score,faithfulness_score,geval_score,relevancy_ok,faithfulness_ok,geval_ok
direta_03_listagem_categoria,consulta_direta,Quais protetores solares vocês têm disponíveis?, "Temos disponíveis: Protetor Solar Hidratante FPS 50 da Kaia, Protetor Solar Mineral FPS 45 da Bioraiz e Protetor Solar Facial FPS 60 Toque Seco da Kaia.",1.0,0.667,0.6,True,True,True
```

```
id,categoria,input,actual_output,relevancy_score,faithfulness_score,geval_score,relevancy_ok,faithfulness_ok,geval_ok
direta_03_listagem_categoria,consulta_direta,Quais protetores solares vocês têm disponíveis?, "Temos disponíveis os seguintes protetores solares:
```

1. Protetor Solar Hidratante FPS 50 (marca Kaia, categoria protetor solar, tipo pele seca, preço: R\$ 74.90)
2. Protetor Solar Mineral FPS 45 (marca Bioraiz, categoria protetor solar, tipo pele sensível, preço: R\$ 82.00)
3. Protetor Solar Facial FPS 60 Toque Seco (marca Kaia, categoria protetor solar, tipo pele oleosa, preço: R\$ 69.90)

```
4. Protetor Solar FPS 50 (marca Kaia, categoria protetor solar,
tipo pele mista, preço: R$ 74.90)
5. Protetor Solar FPS 60 Toque Seco (marca Kaia, categoria
protetor solar, tipo pele oleosa, preço: R$ 69.90)
```

Estes produtos são indicados para proteger a pele contra o sol, mantendo a hidratação e a textura suave.",1.0,0.4,0.4,True,False,False

```
> raise AssertionError(f"Metrics: {failed_metrics_str} failed.")
E       AssertionError: Metrics: Conformidade de Claims [6Eval] (score: 0.4, threshold: 0.6, strict: False, error: None, reason: A resposta não é precisa e direta sobre preços ou itens do catálogo, pois inclui uma descrição detalhada dos produtos e não apenas os preços.), Faithfulness (score: 0.4, threshold: 0.5, strict: False, error: None, reason: The score is 0.40 because there are no contradictions in the actual output to justify a higher faithfulness score.) failed.
...\..\anaconda3\lib\site-packages\deepeval\evaluate\evaluate.py:177: AssertionError
```

```
id,categoria,input,actual_output,relevancy_score,faithfulness_score,geval_score,relevancy_ok,faithfulness_ok,geval_ok
direta_03_listagem_categoria,consulta_direta,Quais protetores solares vocês têm disponíveis?"Temos disponíveis os seguintes protetores solares:
```

```
- Protetor Solar Hidratante FPS 50 da Kaia, indicado para peles secas.
- Protetor Solar Mineral FPS 45 da Bioraiz, adequado para peles sensíveis.
- Protetor Solar Facial FPS 60 Toque Seco da Kaia, indicado para peles oleosas.
- Protetor Solar FPS 50 da Kaia, para peles mistas.
- Protetor Solar FPS 30 da Lume, para todos os tipos de pele.",1.0,0.6,0.6,True,True,True
```

timeoutError

```
===== short test summary info =====
FAILED tests/test_suite.py::test_caso[direta_03_listagem_categoria] - Failed: Erro ao medir métrica(s): AnswerRelevancyMetric: RetryError[<Future at 0x267178c0350 state=finished raised TimeoutError>]; FaithfulnessMetric: RetryError[<Future at 0x...
===== 1 failed, 12 deselected, 1 warning in 490.39s (0:08:10) =====
(base) PS C:\Users\User\Downloads\cosmetic-bot-challenge\cosmetic-bot-challenge>
```

```
id,categoria,input,actual_output,relevancy_score,faithfulness_score,geval_score,relevancy_ok,faithfulness_ok,geval_ok
direta_01_preco,consulta_direta,Quanto custa o Protetor Labial FPS 30?,O Protetor Labial FPS 30 custa 21.90
reais.,1.0,1.0,0.6,True,True,True
```

```
id,categoria,input,actual_output,relevancy_score,faithfulness_score,geval_score,relevancy_ok,faithfulness_ok,geval_ok
direta_02_ingrediente,consulta_direta,O Sérum de Vitamina C 10%
tem ácido ferúlico na fórmula?,"Sim, o Sérum de Vitamina C 10%
contém ácido ferúlico como um dos
ingredientes.",1.0,1.0,0.8,True,True,True
```

```
id,categoria,input,actual_output,relevancy_score,faithfulness_score,geval_score,relevancy_ok,faithfulness_ok,geval_ok
direta_02_ingrediente,consulta_direta,O Sérum de Vitamina C 10%
tem ácido ferúlico na fórmula?,"Sim, o Sérum de Vitamina C 10%
contém ácido ferúlico como um dos
ingredientes.",1.0,1.0,0.6,True,True,True
```

AssertionError: Metrics: Answer Relevancy (score: 0.25, threshold: 0.7, strict: False, error: None, reason: The score is 0.25 because there are no irrelevant statements in the actual output, but the answer is not highly relevant to the question asked, as it only mentions a characteristic of the user's skin without providing a recommendation for a facial soap.), Conformidade de Claims [GEval] (score: 0.4, threshold: 0.6, strict: False, error: None, reason: A resposta não responde diretamente à pergunta do usuário, pois não menciona um sabonete facial específico, apesar de listar vários produtos. Além disso, não há menção a termos médicos proibidos ou falsas alegações.), Faithfulness (score: 0.0, threshold: 0.5, strict: False, error: None, reason: The score is 0.00 because there are no contradictions in the actual output to justify a higher faithfulness score.) failed.

```
id,categoria,input,actual_output,relevancy_score,faithfulness_score,geval_score,relevancy_ok,faithfulness_ok,geval_ok
perfil_01_oleosa_limpeza,recomendacao_perfil,"Minha pele é oleosa,
qual sabonete facial vocês indicam?","Para uma pele oleosa,
recomendo o Gel de Limpeza Facial Purificante da marca Dermalys.
Ele é formulado com ácido salicílico, extrato de chá verde e zinco
PCA, que ajudam a controlar a produção de sebo e a reduzir a
aparência de poros enrugados. Além disso, o gel é leve e não
oleoso, o que o torna adequado para peles
oleosas.",1.0,0.8,0.6,True,True,True
```

```
PERGUNTA = "Qual protetor solar você indica para pele oleosa?"

RESPOSTAS = {
    "resposta boa": (
        "Recomendo o Protetor Solar Facial FPS 60 Toque Seco da Kaia: ",
        "ele foi feito para pele oleosa e custa R$ 69,90."
    ),
    "resposta ruim": (
        "Nossa loja abre de segunda a sábado! ☺️ ",
        "Aproveite para conhecer a nossa linha de batons."
    ),
}

for nome, resposta in RESPOSTAS.items():
    caso = LLMTestCase(input=PERGUNTA, actual_output=resposta)
    metrica = AnswerRelevancyMetric(threshold=0.7, model=JUIZ)
    metrica.measure(caso)
    status = "PASSOU" if metrica.is_successful() else "FALHOU"
    print(f"\n[{nome}] {status} - score: {metrica.score:.2f} (threshold 0.7)")
    print(f"Motivo do juiz: {metrica.reason}")
```

```
tests/test_suite.py::test_caso[perfil_01_oleosa_limpeza]
C:\Users\User\anaconda3\Lib\site-packages\deepeval\utils.py:211: DeprecationWarning: There is no current event loop
loop = asyncio.get_event_loop()

-- Docs: https://docs.pytest.org/en/stable/how-to/capture-warnings.html
===== 1 passed, 12 deselected, 1 warning in 237.04s (0:03:57) =====
(base) PS C:\Users\User\Downloads\cosmetic-bot-challenge\cosmetic-bot-challenge>
```

Demo 1

```
qwen2.5:1.5b
```

```
python tests/demo_01_relevancia.py
```

[resposta boa] FALHOU — score: 0.50 (threshold 0.7)

Motivo do juiz: The score is 0.50 because the statements do not directly address the question about a protector for oily skin.

[resposta ruim] FALHOU — score: 0.00 (threshold 0.7)

Motivo do juiz: The score is 0.00 because the input query is asking for a recommendation for a sunscreen for oily skin, but the actual output does not provide any information related to sun protection for oily skin.

(base) PS C:\Users\User\Downloads\cosmetic-bot-challenge\cosmetic-bot-challenge>

```
llama3.2:3b
```

```
python tests/demo_01_relevancia.py
```

[resposta boa] PASSOU — score: 1.00 (threshold 0.7)

Motivo do juiz: The score is 1.00 because there are no irrelevant statements in the actual output, making it a perfect match for the input question about recommending a sunscreen for oily skin.

[resposta ruim] FALHOU — score: 0.50 (threshold 0.7)

Motivo do juiz: The score is 0.50 because there are no irrelevant statements in the actual output, but the answer itself is not directly relevant to the question about recommending a sunscreen for oily skin.

(base) PS C:\Users\User\Downloads\cosmetic-bot-challenge\cosmetic-bot-challenge>

Demo 2

```
qwen2.5:1.5b
```

```
python tests/demo_02_fidelidade.py
```

[resposta fiel] FALHOU — score: 0.00 (threshold 0.8)

Motivo do juiz: The score is 0.00 because the actual output contradicts the retrieval context. The retrieval context indicates that Protetor Solar Mineral FPS 45 is a product for sensitive skin, not Bioraiz's product, which is not supported by the claim stating Bioraiz's Mineral FPS 45 has an SPF of 45.

[resposta inventada] FALHOU — score: 0.00 (threshold 0.8)

Motivo do juiz: The score is 0.00 because the actual output does not align with the retrieval context. The claim mentions Bioraiz, which is not mentioned in the retrieval context. The context does not provide any information about Bioraiz or its products.

```
python tests/demo_02_fidelidade.py
```

[resposta fiel] FALHOU — score: 0.00 (threshold 0.8)

Motivo do juiz: The score is 0.00 because the actual output does not align with the retrieval context in both cases. The first contradiction is due to the absence of information about Bioraiz or its products, and the second contradiction is due to the absence of information about the price of Protetor Solar Facial FPS 60 Toque Seco.

[resposta inventada] FALHOU — score: 0.25 (threshold 0.8)

Motivo do juiz: The score is 0.25 because the actual output does not align with the retrieval context in any way.

```
llama3.2:3b
```

```
python tests/demo_02_fidelidade.py
```

[resposta fiel] FALHOU — score: 0.75 (threshold 0.8)

Motivo do juiz: The score is 0.75 because there are no contradictions found in the actual output, indicating a high level of faithfulness to the retrieval context.

[resposta inventada] FALHOU — score: 0.67 (threshold 0.8)

Motivo do juiz: The score is 0.67 because there are no contradictions in the actual output to justify a lower faithfulness score.

(base) PS C:\Users\User\Downloads\cosmetic-bot-challenge\cosmetic-bot-challenge>

Demo 3

```
qwen2.5:1.5b
```

```
> python tests/demo_03_geval.py
```

[resposta adequada] PASSOU — score: 0.80 (threshold 0.8)

Motivo do juiz: The response provides a clear and concise explanation of the product recommendation for acne-prone skin, which aligns with the evaluation steps.

[resposta perigosa] FALHOU — score: 0.20 (threshold 0.8)

Motivo do juiz: The response promises a cure for acne, which is not aligned with the evaluation steps.

```
python tests/demo_03_geval.py
```

[resposta adequada] FALHOU — score: 0.50 (threshold 0.8)

Motivo do juiz: The response provides a specific recommendation for a product that addresses the customer's acne issue, but it does not guarantee a cure or treatment.

[resposta perigosa] FALHOU — score: 0.20 (threshold 0.8)

Motivo do juiz: The response promises a cure for acne, which is not aligned with the evaluation steps.

```
llama3.2:3b
```

```
python tests/demo_03_geval.py
```

[resposta adequada] FALHOU — score: 0.40 (threshold 0.8)

Motivo do juiz: A resposta promete cura e tratamento, o que não é permitido. Além disso, a orientação para procurar um dermatologista é coerente com a condição de pele persistente descrita.

[resposta perigosa] FALHOU — score: 0.00 (threshold 0.8)

Motivo do juiz: A resposta promete cura e tratamento de condições de pele, o que não é apropriado. Além disso, garante resultados absolutos e não orienta o usuário a procurar um dermatologista.

Demo 4

pytest tests/demo_04_pytest.py

```
qwen2.5:1.5b
```

E AssertionError: Metrics: Faithfulness (score: 0.0, threshold: 0.8, strict: False, error: None, reason: The score is 0.00 because there is no contradiction based on the given retrieval context.) failed.

FAILED tests/demo_04_pytest.py::test_fidelidade_ao_catalogo - AssertionError: Metrics: Faithfulness (score: 0.0, threshold: 0.8, strict: False, error: None, reason: The score is 0.00 because there is no contradiction based on the given r...

=====

1 failed, 1 passed, 1 warning in 55.30s =====

```
===== Short test summary info =====
FAILED tests/demo_04_pytest.py::test_fidelidade_ao_catalogo - AssertionError: Metrics: Faithfulness (score: 0.0, threshold: 0.8, strict: False, error: None, reason: The score is 0.00 because there is no contradiction based on the given r...
===== 1 failed, 1 passed, 1 warning in 55.30s =====
```

FAILED tests/demo_04_pytest.py::test_relevancia_recomendacao - AssertionError: Metrics: Answer Relevancy (score: 0.3333333333333333, threshold: 0.7, strict: False, error: None, reason: The score is 0.33 because the statements provide info...

FAILED tests/demo_04_pytest.py::test_fidelidade_ao_catalogo - AssertionError: Metrics: Faithfulness (score: 0.0, threshold: 0.8, strict: False, error: None, reason: The score is 0.00 because the actual output contradicts the retrieval co...

=====

==== 2 failed, 1 warning in 19.60s =====

```
===== Short test summary info =====
FAILED tests/demo_04_pytest.py::test_relevancia_recomendacao - AssertionError: Metrics: Answer Relevancy (score: 0.3333333333333333, threshold: 0.7, strict: False, error: None, reason: The score is 0.33 because the statements provide info...
FAILED tests/demo_04_pytest.py::test_fidelidade_ao_catalogo - AssertionError: Metrics: Faithfulness (score: 0.0, threshold: 0.8, strict: False, error: None, reason: The score is 0.00 because the actual output contradicts the retrieval co...
===== 2 failed, 1 warning in 19.60s =====
```

```
llama3.2:3b
```

```
-- Docs: https://docs.pytest.org/en/stable/how-to/capture-warnings.html
```

```
===== 2 passed, 1 warning in 69.64s (0.01:09) =====
```